

Clasificación de las fases del sueño

Aprendizaje Automático

Martín Sande Costa

martin.sande@udc.es

Raúl Paris González

raul.paris@udc.es

Alejandro Fernández Luces

alejandro.fernandez.luces@udc.es

Jennifer Dubra Rey

jennifer.dubra@udc.es

María Taboada Pena

maria.taboada.pena@udc.es



UNIVERSIDADE DA CORUÑA

Grado en Ingeniería Informática Mención de Computación

A Coruña - 12 de marzo de 2018

ÍNDICE

1. [Introducción](#)
 - 1.1. [Objetivos](#)
 - 1.2. [Problemática asociada](#)
2. [Descripción del problema](#)
3. [Análisis bibliográfico y últimos avances](#)
 - 3.1. [Breve resumen de trabajos utilizando redes neuronales y SVM](#)
 - 3.2. [Sumario de diferentes trabajos con otras técnicas](#)
4. [Desarrollo](#)
 - 4.1. [Aproximación 1](#)
 - 4.1.1. [RNA](#)
 - 4.1.2. [SVM](#)
 - 4.1.3. [k-NN](#)
 - 4.1.4. [Discusión](#)
 - 4.2. [Aproximación 2](#)
 - 4.2.1. [RNA](#)
 - 4.2.2. [SVM](#)
 - 4.2.3. [k-NN](#)
 - 4.2.4. [Discusión](#)
 - 4.3. [Aproximación 3](#)
 - 4.3.1. [Estudios preliminares](#)
 - 4.3.2. [RNA](#)
 - 4.3.3. [SVM](#)
 - 4.3.4. [k-NN](#)
 - 4.3.5. [Discusión](#)

4.4. [Aproximación 4](#)

4.4.1. [Estudios preliminares](#)

4.4.2. [RNA](#)

4.4.3. [SVM](#)

4.4.4. [k-NN](#)

4.4.5. [Discusión](#)

5. [Conclusiones](#)

6. [Trabajo futuro](#)

7. [Bibliografía](#)

1 - INTRODUCCIÓN

En los últimos años se ha consolidado un nuevo campo dentro de las ciencias de la computación que abarcaría un conjunto de metodologías caracterizadas por su inspiración en los sistemas biológicos para resolver problemas relacionados con el mundo real (reconocimiento de formas, toma de decisiones, etc.), ofreciendo soluciones robustas y de fácil implementación. De entre estas metodologías, las Redes Neuronales Artificiales son las que actualmente están causando un mayor impacto, debido a su extraordinaria aplicabilidad práctica. Además, el procesamiento de señales ha sido un tema de investigación de peso en los últimos años. Siendo la razón principal que gran parte de los problemas del mundo real producen señales que los caracterizan.

Esta memoria trata de aglutinar los logros alcanzados en este trabajo en el que aplicamos esta técnica, además de otras dos: máquinas de soporte vectorial y k-NN (k nearest neighbors). Clasificamos varias señales (electroencefalograma, temperatura corporal, electrooculograma) en distintos pacientes e identificamos las correspondientes fases del sueño en que se encuentra.

Entre los trabajos publicados anteriormente destacan varios realizados con redes neuronales, con SVM², con sistemas neuro difusos y combinaciones de las anteriores.

En la sec. 3 se puede encontrar un estado de los últimos avances en este campo, hemos considerado incluir un breve resumen de los estudios realizados con redes neuronales y máquinas

de soporte vectorial (sec. 3.1) y un sumario de diferentes trabajos en extracción automática de características, clasificación automática, y clasificación automática de electroencefalogramas (sec. 3.2). La sección 4 contiene la descripción completa del modelo y el desarrollo que se utilizó para este problema en concreto. Los tests elaborados con este sistema, la comparación con trabajos anteriores y las conclusiones se encuentran en la sección 5 y finalmente, los trabajos futuros se pueden encontrar en la sección 6.

¹ Modelo oculto de Márkov.

² Máquinas de soporte vectorial

1.1 - OBJETIVOS DEL TRABAJO

El trabajo presentado se puede enmarcar dentro de los epígrafes de clasificación de señales; siendo los principales objetivos con los que vamos a trabajar los siguientes:

1. Demostrar que la técnica descrita aquí, puede obtener mejores resultados que las técnicas clásicas basadas en la extracción manual. A tal fin, realizamos una comparación final entre los resultados obtenidos con esta técnica y otros encontrados en la bibliografía. Estos resultados muestran que la técnica empleada mejora considerablemente los resultados obtenidos clásicamente.
2. Obtención de mejores resultados en la clasificación de las fases del sueño comparándolos con los obtenidos en los estudios realizados previamente que encontramos.

1.2 - PROBLEMÁTICA ASOCIADA

La clasificación de fases del sueño tiene múltiples aplicaciones, como puede ser el estudio de la función y disfunción del sistema nervioso producida por enfermedades del cerebro. Los datos obtenidos, cuando se interpretan en el contexto clínico del paciente permiten diagnosticar o ayudar al diagnóstico del proceso neurológico, así como cuantificar, monitorizar y valorar su evolución.

Los trastornos del sueño constituyen un grupo muy numeroso y heterogéneo de procesos. Hay muchísimas enfermedades que cursan con algún trastorno del sueño como uno más de sus

síntomas. De hecho, es difícil encontrar alguna enfermedad que no altere en nada el sueño nocturno o la tendencia a dormir durante el día. Por ello, las clasificaciones han buscado clasificar los trastornos del sueño como enfermedades propias y no sólo como síntomas. Sin embargo, el modo de clasificar tales enfermedades se ha basado, en la mayoría de los casos, en el síntoma principal, y por ello se dividían en insomnios, hipersomnias, parasomnias, etc.

Por este motivo la clasificación automática de estas señales presenta una gran ventaja a la hora de realizar el diagnóstico del paciente.

2 - DESCRIPCIÓN DEL PROBLEMA

Dormir pasó de ser considerado un fenómeno pasivo en el que parecía no ocurrir aparentemente nada, a descubrir que podemos llegar a tener una actividad cerebral tan activa como en la vigilia y en el que ocurren grandes modificaciones en el funcionamiento del organismo; cambios en la presión arterial, la frecuencia cardíaca y respiratoria, la temperatura corporal, la secreción hormonal, entre otros.

Se empezó a estudiar el sueño científicamente a través de los registros de la actividad electroencefalográfica y hoy en día sigue en pie la propuesta de Dement y Kleitman en una estructuración del sueño en ciclos, es decir, sucesiones de fases, de entre 90 y 110 minutos aproximadamente. Describiremos al final de este capítulo las cinco fases del sueño, que a su vez se pueden dividir en los períodos de ondas lentas durante la primera mitad de la noche y los de ondas rápidas, más conocidos como “sueño REM” que es más frecuente a medida que avanza la noche.

Antes de explicar las fases del sueño debemos tener una serie de conceptos claros para poder entenderlo con mayor claridad:

- **Electroencefalografía, o EEG**

Este ha sido uno de los primeros métodos desarrollados para "leer" la actividad del cerebro, es decir, los patrones de disparo eléctrico que lo recorren. La técnica es relativamente sencilla, y consiste en dejar fijados unos electrodos en el cuero cabelludo de la persona para que estos capten los impulsos eléctricos que suceden justo debajo para mandar esta información a una máquina. La máquina recoge estos datos y los expresa en

forma de líneas y picos de actividad mediante un trazador gráfico, del mismo modo en el que trabajan los sismógrafos que miden la intensidad de los terremotos.

El EEG se puede utilizar tanto para medir la actividad de unas pocas neuronas o de zonas más amplias de la corteza cerebral. Se utiliza mucho para estudiar casos de epilepsia, así como las ondas cerebrales del sueño, pero no permite saber exactamente en qué parte del encéfalo se inician esos patrones de activación.

La actividad eléctrica de las neuronas que pueblan el cerebro humano forma parte de la base de todos los pensamientos, sentimientos y de los actos que realizamos. Todo aquello que conforma nuestra vida mental consiste en ese salto inexplicable que va desde la frecuencia con la que las neuronas simplemente mandan impulsos eléctricos a la transformación en procesos mentales con toda su complejidad. Hay algo en la manera de coordinarse entre sí de estas células nerviosas que hace que aparezcan sensaciones, pensamientos, recuerdos, etc.

Las ondas cerebrales pueden ser clasificadas en diferentes tipos según su frecuencia, es decir, el tiempo que pasa entre los momentos en los que las neuronas disparan señales eléctricas a la vez.

Estos tipos de ondas cerebrales reciben el nombre de ondas Delta, Theta, Alfa, Beta y Gamma.

- Ondas Delta (1 a 3 Hz)

Las ondas Delta son las que tienen mayor amplitud de onda, es decir, que su frecuencia es muy baja. Características de la fase de sueño profundo, que es aquella en la que raramente soñamos. Que representen esta fase no significa que el cerebro esté relativamente apagado, sino que está ocupado con procesos que no dependen de que se esté en un estado de consciencia.

- Ondas Theta (3,5 a 7,5 Hz)

Están asociadas a los estados de calma profunda, relajación e inmersión en los recuerdos y las fantasías, y también con la etapa de sueño REM, que es aquella en la que soñamos. Por consiguiente, cuando aparecen estas ondas se estima que sí hay consciencia (o que es muy probable que la haya), pero es una consciencia

desconectada de lo que ocurre a nuestro alrededor y centrada en experiencias imaginarias.

- Ondas Alfa (8 a 13 Hz)

Las Alfa siguen estando relacionada con los estados de relajación. No son propias del estado de sueño, pero sí de calma profunda, como un paso intermedio.

- Ondas Beta (12 a 33 Hz)

Aquí la actividad neuronal es intensa. Están relacionadas con acciones que requieren permanecer en un cierto estado de alerta y de gestión ágil de la atención, como por ejemplo el proceso de responder a una pregunta de examen.

Así pues, este tipo de ondas cerebrales está vinculado a un manejo ágil del foco de la atención, dependiendo de los objetivos, y con la preocupación por lo que ocurre en el presente, normalmente a nuestro alrededor, ya que hay que reaccionar rápidamente ante posibles imprevistos.

- Ondas Gamma (25 a 100 Hz)

Estas son el tipo de ondas cerebrales con una mayor frecuencia y menor amplitud. Aparecen en estados de vigilia y se cree que su presencia está relacionada con la aparición de la consciencia, con la ampliación del foco atencional y con la gestión de la memoria.

Una vez aclarado podemos dar paso a la explicación de las fases y ciclos del sueño que como hemos mencionado con anterioridad podemos dividirlos en dos grandes grupos:

- **Sueño de ondas lentas o sueño no REM:**

Lo constituyen cuatro estadios (aproximadamente el 80% del sueño total), en los que se va profundizando progresivamente en el sueño (fases I, II, III y IV). La actividad cerebral, registrada mediante EEG, pasa de ondas Gamma que se van progresivamente transformando en ondas Delta. El tono muscular va descendiendo, dejando nuestro cuerpo cada vez más relajado e inmóvil, así como el ritmo respiratorio y cardíaco y los lentos movimientos oculares del inicio del sueño desaparecen por completo. La

progresión de la fase I a la IV dura aproximadamente 90 minutos y comporta una profundización en el sueño que implica mayor aislamiento sensorial del entorno y por tanto mayores dificultades para despertar, que llegan al grado máximo en la fase IV.

Los cambios orgánicos que se producen en esta fase del sueño, han llevado a los científicos a apuntar su relación con la recuperación física del organismo (regeneración y recuperación de energía), concluyendo que la desaparición del sueño profundo puede desencadenar problemas médicos importantes (problemas de crecimiento, déficit hormonales, etc.).

- **Sueño MOR, REM o de los Movimientos Oculares Rápidos:**

Aparece por primera vez aproximadamente a los 90 minutos de quedarnos dormidos. La actividad cerebral se parece más a la que presentamos en vigilia. Sin embargo, hay una importante diferencia respecto a esta, y es que en este caso, la actividad no es provocada por estímulos externos percibidos a través de los sentidos, sino por los ensueños o sueños que tienen lugar en esta fase. Una de las cosas que caracteriza a esta fase del sueño es la pérdida del tono muscular, protegiéndonos así de lesionarnos o tener los problemas derivados de mover nuestro cuerpo en respuesta a los sueños. Esta fase del sueño también se caracteriza por la aparición de movimientos oculares rápidos.

A lo largo de la noche, este tipo de sueño se va alternando con las distintas fases del sueño no REM, aunque la mayor parte del sueño REM se produce al final de la noche. Por este motivo, cuánto más tarde nos levantamos más probabilidades tenemos de recordar los sueños, puesto que recordamos los sueños cuando nos despertamos a partir de esta fase. Los cambios que se producen en esta fase, han llevado a los científicos a apuntar la relación que puede tener el sueño REM con la consolidación y recuerdo de lo que aprendemos durante el día. El hecho de que la cantidad de sueño REM cambie a lo largo del ciclo vital, de modo que los bebés y niños tengan más sueño de este tipo que los adultos, y éstos que los ancianos, parece confirmar esta hipótesis, ya que participa en funciones de reorganización neuronal y aprendizaje.

Sueño no REM	Fase I: adormecimiento <ul style="list-style-type: none"> ● Supone menos del 5% el sueño total ● Constituida por períodos transicionales entre la vigilia y el sueño ● Aparece cuando nos estamos quedando dormidos y también entre los distintos ciclos del sueño ● Perdemos progresivamente la conciencia del entorno ● Es habitual que nos despierten ruidos relativamente poco intensos ● Se registran principalmente ondas Alfa y empiezan a aparecer ondas Theta
	Fase II: sueño ligero <ul style="list-style-type: none"> ● Es la más frecuente de las 5, llegando a constituir aproximadamente el 50% del sueño nocturno total. ● Disminución significativa de la actividad fisiológica y muscular ● Aparición de los husos del sueño y los complejos K; estos términos describen oscilaciones en la actividad cerebral que promueven el sueño profundo, inhibiendo la posibilidad de despertarse. ● Mayor presencia de ondas Theta
	Fases III y IV: sueño delta o profundo. A diferencia del modelo de Dement y Kleitman[1], hoy en día se suele hablar de ambas conjuntamente. <ul style="list-style-type: none"> ● Ocupa entre un 15 y un 25% del total ● Actividad fisiológica muy disminuida ● Aumento del tono muscular ● Se considera que nuestro cuerpo descansa y se recupera más marcadamente en estas fases que en el resto ● En estas fases se producen la mayor parte de los episodios de terrores nocturnos, sonambulismo, somniloquia y enuresis nocturna ● Predominan las ondas Delta
Sueño REM	Fase V: Sueño de ondas rápidas o REM <ul style="list-style-type: none"> ● Constituye un 20% del sueño total ● Movimientos oculares rápidos (REM: “rapid eye movements”) ● Fuerte disminución del tono muscular ● Aumento de la actividad fisiológica, de forma opuesta al sueño profundo ● Mayor presencia de sueño vívidos y narrativos durante las horas que preceden al despertar ● En la fase REM se dan las pesadillas ● Predominan las ondas Beta y las Theta

La base de datos utilizada ha sido extraída de la página web physionet.org [2]. Contiene polisomnogramas acompañados de hipnogramas obtenidos de hombres y mujeres de origen caucásico entre 21 y 35 años sin ninguna medicación [3]. Esta polisomnografía es una prueba usada para el estudio del sueño, formada por:

- EOG horizontal (mide el movimiento de los ojos) y EEG's Fpz-Cz y Pz-Oz muestreados a 100Hz. Fpz-Cz y Pz-Oz, son posiciones craneales.
 - Fpz-Cz: del lóbulo frontal hasta el lóbulo central.
 - Pz-Oz: desde el lóbulo parietal hasta el lóbulo occipital.
- EMG submental (registra gráficamente la actividad eléctrica producida por los músculo), respiración oronasal (tipo de respiración que consiste en tomar el aire por la nariz y expulsarlo por la boca) y temperatura corporal rectal muestreados a 1Hz.
- El hipnograma (representación gráfica de las diferentes fases de sueño a lo largo de una noche de registro) tiene una muestra cada 30 segundos. Los posibles valores del hipnograma son:
 - W :despierto, valor 0
 - R: fase REM, valor 5
 - 1, 2, 3 y 4 : cada uno asociado a la fase con el mismo número
 - M: movimiento corporal, valor 6
 - Y una etapa sin puntuación con valor 9.

En la base de datos hay dos tipos de individuos, unos de los que se han obtenido los datos sólo cuando estaban dormidos y otros de los que se han obtenido datos a lo largo del día, tanto despiertos como dormidos. Los del primer grupo no cuentan con información sobre la temperatura corporal.

3 - ANÁLISIS BIBLIOGRÁFICO Y ÚLTIMOS AVANCES

Se han publicado técnicas basadas en una única o varias señales para la automatización de la clasificación de las etapas del sueño.

Autor	Señales utilizadas	Extracción de características	Fases del sueño	Método utilizado para la	Precisión
-------	--------------------	-------------------------------	-----------------	--------------------------	-----------

			clasificadas	clasificación	
Huang, C.-S [4]	EGG (Fp1 y Fp2)	Transformada de Fourier (Reducida)	5 fases	SVM multiclase	71%
Radha, M [5]	6 señales EEG (canal único)	Transformada de Fourier y características no lineales	5 fases	RF y SVM	RF > SVM
Yu, S [6]	EEG (triple canal)	-	2 estados (despierto y mareado)	SVM	98%
Jo, H.G. [7]	EEG (canal único)	Grafo de visibilidad	6 fases	SVM multiclase	87.5%
Gudmundsson, S. [8]	EEG (canal único)	Características de energía (dominio del tiempo)	5 fases	Elman recurrent neural classifier	87.2%
Le, Q.K.[9]	EEG, 2 EOG, 1 EMG	Zero Crossing	5 fases	k-mean clustering mejorado	75%
Lajnef, T. [10]	PSG, EEG (dos canales), 2 EOG y EMG	Transformada de Fourier	-	SVM basado en dendrogramas	92%
Phan, H. [11]	EEG (canal único)	-	2 estados en una aproximación y 4 fase en la segunda aproximación	k-NN	98.32% y 94.39% respectivamente
Hassan, A.R[12]	EEG (canal único)	-	6 estados	Empaquetado (agregación de Bootstrap)	85.57% - 95.05%
Hassan, A.R [13]	EEG (canal único)	Transformada de Fourier	6 estados	CEEMDAN	86.89% - 99.48%
Rodríguez-Sotelo[14]	EEG (2 canales)	-	-	J-Means clustering y algoritmo-Q	80%

Lan, K.-C. [15]	PSG (multicanal)	Transformada de Fourier de la ondícula continua	6 estados	Decision Tree	84%
Fraiwan, L. [16]	EEG (canal único)	Transformada de Fourier de la ondícula continua	6 estados	RNA	84%
Fraiwan, L. [17]	EEG (canal único)	Triple frecuencia	-	Random Forests	83%

Hemos analizado algunos de estos estudios en los dos siguientes apartados.

3.1 - BREVE RESUMEN DE PUBLICACIONES UTILIZANDO RNA, SVM Y k-NN

El estudio realizado por Huang, C.-S [4] segmenta señales de EEG de dos canales (Fp1 y Fp2) en componentes pseudo estacionarios. Además extrae características utilizando la transformada de Fourier de término reducido; relacionada con la transformada de Fourier usada para determinar el contenido en frecuencia sinusoidal y de fase en secciones locales de una señal así como sus cambios con respecto al tiempo. Se utiliza un grupo de los principales algoritmos de agrupamiento difuso, FCM (fuzzy C-means), donde cada elemento tiene un grado de pertenencia difuso a los grupos y se usó SVM multiclase para desarrollar un sistema ASSC¹. El resultado de este trabajo proporcionó una precisión del 71%.

Radha, M [5] utilizó 6 señales de EEG y varias técnicas de procesamiento de señales, como el dominio del tiempo, el dominio de la frecuencia y características no lineales. Adicionalmente, RF² y SVM se utilizaron para la clasificación de 5 etapas del sueño. El objetivo de este trabajo fue desarrollar un algoritmo online para la ASSC usando una señal EEG con un único canal. Los resultados mostraron que el mejor rendimiento se encontró usando señales del EEG frontal, con características lineales espectrales³ y un RF consiguió un rendimiento mayor que SVM.

En *Support vector machine based detection of drowsiness using minimum EEG features* [6], se usó la aproximación de un clasificador basado en SVM para distinguir entre pacientes despiertos y mareados usando una señal de EEG de triple canal. El estado mareado se definió como una combinación entre los estados del sueño 1 y 2, alcanzando una precisión del 98%.

¹ Automatic Sleep Stage Classification

² Random Forests

³ Características extraídas del dominio de la frecuencia

Por otra parte, el estudio de Jo, H.G. [7] realizó un sistema ASSC basado en la extracción de 9 características de un VG¹ y un HVG² usando un solo canal de una señal EEG, y un clasificador multiclase SVM de 6 etapas que consiguió una precisión del 87.5%. Gudmundsson,

S. [8] clasificó 5 etapas del sueño basándose en 6 características de energía de una señal EEG de un canal usando el ERNC³ con una precisión en la clasificación del 87.2%. Le, Q.K. [9] utilizó 4 señales EEG, 2 EOG⁴ y 1 EMG⁵ de las cuales extrajo la proporción, potencia y características ZC⁶, respectivamente. Además, usó un algoritmo k-means clustering mejorado para clasificar los datos en 5 fases. El algoritmo mostró una precisión del 75%, que superó la precisión del algoritmo k-means clustering original.

Lajnef, T.[10] exploró un amplio rango de características del dominio del tiempo y la frecuencia de una señal de un PSG⁷ que incluía dos canales EEG, dos EOG y un EMG. El método propuesto consiguió una precisión del 92% utilizando un SVM basado en dendrogramas⁸.

Phan, H. [11] utilizó el método k-NN para clasificar en una primera aproximación entre los estados dormido/desperto y en una segunda aproximación entre los estados: despierto, fase 1+REM, fase 2 y dormido profundo, consiguiendo unas precisiones del 98.32% y 94.49% respectivamente. Se usó una señal de EEG de un solo canal.

¹ Visibility Graph

² Horizontal Visibility Graph

³ Elman recurrent neural classifier

⁴ Electrooculograma

⁵ Electromiograma

⁶ Zero Crossing

⁷ Polisomnograma

⁸ Tipo de representación gráfica o diagrama de datos en forma de árbol

3.2 - OTRAS TÉCNICAS DE CLASIFICACIÓN

Hassan, A.R. [12] utilizó un algoritmo de agregación de bootstrap, también conocido como empaquetado, con varias características estadísticas y espectrales de un único canal EEG. En la siguiente tabla se pueden observar las precisiones de esta técnica según el número de etapas clasificadas:

6 etapas	5 etapas	4 etapas	3 etapas	2 etapas
85.57%	86.53%	87.49%	89.77%	95.05%

Similarmente, un estudio realizado por el mismo autor (Hassan, A.R.) [13] propuso un método de ASSC utilizando una señal EEG de canal único usando una variante del algoritmo EMD con ruido adaptativo (CEEMDAN). Este método descompone las señales y puede ser comparado con otros métodos de análisis como la transformada de Fourier o la transformada de la ondícula. En la siguiente tabla se pueden observar las precisiones de esta técnica según el número de etapas clasificadas:

6 etapas	5 etapas	4 etapas	3 etapas	2 etapas
86.89%	90.69%	92.14%	94.10%	99.48%

Rodríguez-Sotelo [14] usó métodos de métrica de entropía, el algoritmo-Q como un método

para reducir la dimensionalidad y J-Means clustering (una nueva heurística para la búsqueda local de sumas mínimas de cuadrados) como ASSP para una señal de EEG de dos canales. El rendimiento para los datos automáticamente diferenciados alcanzó una precisión de clasificación óptima con picos del 80%.

Otro estudio de Lan, K.-C. [15] extrajo varias características espectrales basándose en la transformada de Fourier de datos de un PSG multi-canal, de esta manera pudo clasificar las etapas del sueño usando un clasificador basado en reglas DT¹ y consiguió una precisión del 84%.

¹ Decision tree

Fraiwan, L. [16] desarrolló una metodología para un sistema ASSC basado en características de entropía de la distribución de Wigner-Ville (WVD), el espectro de Hilbert-Hough (HHS) y utilizando la transformada de la ondícula continua (CWT) usando una señal EEG de único canal y redes neuronales artificiales. La precisión de la clasificación de la WVD fue del 84%, que superó el resto de aproximaciones. Las características de entropía que extrajo Fraiwan, L. [17] fueron de una señal de EEG con canal único utilizando técnicas de triple frecuencia. La precisión del 83% que se alcanzó con este método y un clasificador RF fue muy similar a la de su anterior trabajo.

Indicaremos en cada fase del desarrollo los estudios en los que nos basamos y que conocimientos utilizamos.

4. DESARROLLO

Se irá observando el desarrollo y comportamiento del sistema en diferentes aproximaciones. Utilizaremos las técnicas anteriormente mencionadas y veremos como van variando los resultados, utilizándolos como base para decidir los objetivos de las próximas aproximaciones.

4.1 Aproximación 1

En esta aproximación se tratará diferenciar entre un sujeto dormido y un sujeto despierto. Para ello, utilizaremos la señal de EEG (de un único canal fpz-cz) y de temperatura corporal. Cada grupo de 30 segundos cuenta con 1 señal de hipnograma, 30 señales de temperatura corporal y 3000 señales de EEG. De los marcos para temperatura corporal y el EEG se ha extraído la media, para que coincidan con la frecuencia del hipnograma.

Además, algunas señales del hipnograma no tienen valores válidos por lo que no se han tenido en cuenta para esta aproximación. Sin embargo, hemos decidido conservar los valores de temperatura anómalos porque no consideramos que influyan al sistema gravemente y no podemos descartar que estos valores sean válidos.

Utilizaremos 4 variables de entrada al sistema: media y desviación típica de la temperatura media y EEG. Contamos con 2830 patrones en cada una de las cuatro características para dividir en conjuntos de entrenamiento, validación y test. Los patrones para cada conjunto se seleccionan de forma aleatoria en cada iteración.

Se ha tomado un 20% de los patrones para elaborar el conjunto de test y otro 20% para el de validación. Para la SVM y el sistema K-NN no hay conjunto de validación.

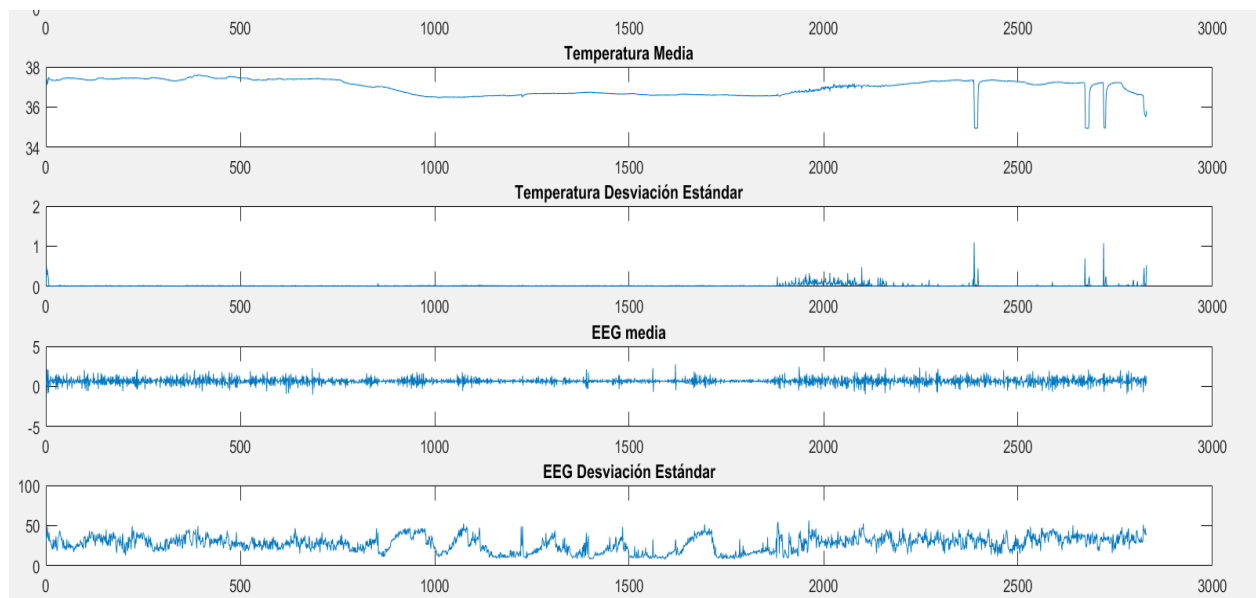


Figura 1. Estructura de las variables de entrada.

4.1.1 RNA

Las pruebas se han realizado con 50 redes neuronales con configuración. En la Tabla 1 se indican los resultados obtenidos para los patrones de test y en la figura 2 se puede observar la matriz de confusión para la mejor arquitectura (una capa oculta con 8 neuronas).

Capas	Error en test	Desviación	Error en	Desviación	Error en	Desviación
-------	---------------	------------	----------	------------	----------	------------

ocultas		típica de error en test	entrenamiento	típica de error en entrenamiento	validación	típica error validación
1	0.1496	0.1238	0.00156	0.1232	0.1612	0.1218
3	0.0748	0.0066	0.0710	0.0081	0.1059	0.0512
5	0.0732	0.00121	0.0692	0.0091	0.1160	0.0381
7	0.0682	0.00146	0.0663	0.0074	0.0955	0.0203
8	0.0584	0.00156	0.0707	0.0089	0.1040	0.0042

Tabla 1. Resultados RNA




Figura 2. Matriz de confusión para la mejor RNA (8 neuronas)

4.1.2 SVM

Se muestran los resultados obtenidos con un kernel lineal, polinómico y gaussiano en las tablas 2, 3 y 4 respectivamente. Debido al alto coste computacional del algoritmo cada iteración tardaba aproximadamente 20 minutos por lo que solo pudimos mostrar una iteración de cada algoritmo. En las siguientes aproximaciones se realizarán más iteraciones.

Kernel lineal			
Media precisión	Desviación precisión	Media error test	Media error entrenamiento
89.60%	0	0.00866	0.00857

Tabla 2. Resultados Kernel lineal

Kernel polinómico				
Orden del polinomio	Media precisión	Desviación típica precisión	Media error test	Media error entrenamiento
2	58.82%	0	0.3445	0.3405

Tabla 3. Resultados Kernel polinómico

Kernel Gaussiano				
Escala	Media de la precisión	Desviación típica de la precisión	Error test	Error entrenamiento
0.2	90.64%	0	0.0848	0.0680

Tabla 4. Resultados Kernel Gaussiano

4.1.3 k-NN

El parámetro utilizado para realizar distintos experimentos es el número de vecinos empleados para tomar la decisión de clasificación. Cabe mencionar que las mejores precisiones fueron

obtenidas con obtenidas con números pares de vecinos. En la tabla 5 y en la figura 3 se muestran los resultados obtenidos.

K-NN Primera Aproximación				
Número de vecinos	Precisión en test	Desviación típica de precisión en test	Precisión en entrenamiento	Desviación típica de precisión en entrenamiento
1	59.39%	0.0162	100%	0
2	65.92%	0.0140	79.69%	0.0052
3	62.55%	0.0175	75.50%	0.0050
4	65.88%	0.0133	75.33%	0.0040
5	63.50%	0.0199	73.58%	0.0052
10	66.19%	0.0118	71.37%	0.0054
20	67.76%	0.0135	69.97%	0.0046
30	68.11%	0.0099	69.49%	0.0038

Tabla 5. Resultados

k-NN

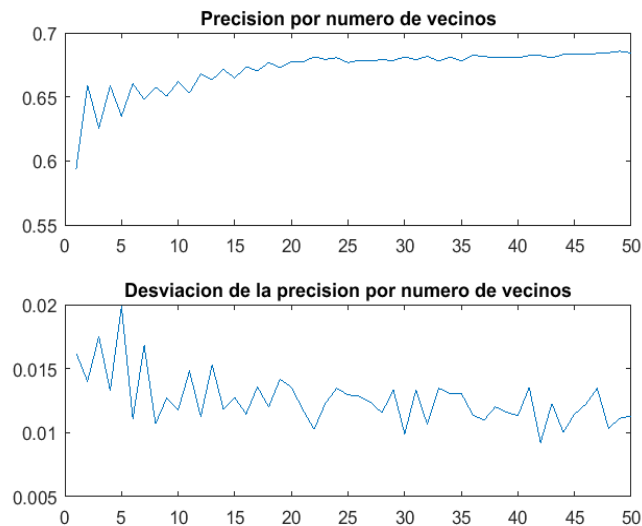


Figura 3. Precisión

k-NN

4.1.4 Discusión

Podemos observar que, en todas las configuraciones, la RNA obtiene más falsos positivos que falsos negativos, siendo positivo dormido y negativo despierto.

Los resultados obtenidos han sido satisfactorios ya que, en el mejor caso, la precisión obtenida en los conjuntos de test ha sido del 96.2%.

Por otro lado, tanto SVM como k-NN ofrecen peores resultados, en especial k-NN. Además SVM ha resultado ser destacablemente el más lento. Esto se debe a que el algoritmo no encontró una función que converja. Por este motivo no hemos podido ejecutar este algoritmo repetidas veces.

La peor precisión obtenida por el SVM fue con el kernel polinómico de grado 4. Tiene un mejor porcentaje de precisión el kernel gaussiano con un 90.64%.

En la Tabla 6 se recoge una comparación entre los mejores sistemas obtenidos con cada técnica y los estudiados previamente en la sección 3.

Autor	Media precisión RNA	Media precisión SVM	Media precisión k-NN
Este estudio	91.51%	78.35%	64.91%
Phan, H. [11]	-	-	98%
Huang, C.-S [4]	-	71%	-
Jo, H.G. [7]	-	87.5%	-
Fraïwan, L. [16]	84%	-	-

Tabla 6. Comparación de resultados

4.2 Aproximación 2

En la siguiente aproximación se intentará realizar una clasificación similar a la seguida por Phan, H. [11]; entre despierto, fase 1 o REM y las demás. La principal razón por la que hacemos esta clasificación se debe a que la fase 1 y la fase REM son las más difíciles de distinguir.

Hemos mantenido las características extraídas con el fin de poder realizar una labor comparativa con la anterior aproximación y comprobar la respuesta del sistema ante la presencia de más clases.

4.2.1 RNA

Las pruebas se han realizado con 50 redes neuronales con configuración. En la Tabla 7, se indican los resultados obtenidos para los patrones de test. Las figuras 4 y 5 reflejan la matriz de confusión y la estructura de la mejor red neuronal.

Capas ocultas	Error en test	Desviación típica de error en test	Error en entrenamiento	Desviación típica de error en entrenamiento	Error en validación	Desviación típica error validación
1	0.001041	0.0137	0.0985	0.0074	0.2118	0.0417
3	0.001013	0.0168	0.0990	0.0076	0.2120	0.0375
5	0.001022	0.0163	0.0996	0.0094	0.2249	0.0481
7	0.001004	0.0133	0.0983	0.0078	0.2272	0.0480
8	0.000992	0.0137	0.0986	0.0080	0.2268	0.0435
10	0.000999	0.0144	0.0971	0.0068	0.2152	0.0400
2 y 2	0.001135	0.0435	0.1136	0.0423	0.2203	0.0429
4 y 3	0.001087	0.0197	0.1098	0.0093	0.2209	0.0375
6 y 2	0.001626	0.0724	0.1583	0.0680	0.2358	0.0568

Tabla 7. Resultados RNA




Figura 4. Matriz de confusión mejor RNA (8 neuronas en la capa oculta)




Figura 5. Red estructural de la RNA

4.2.2 SVM

Se muestran los resultados obtenidos con un kernel lineal, polinómico y gaussiano en las tablas 8, 9 y 10 respectivamente.

Kernel lineal				
Fases	Media error test	Desviación error test	Media error entrenamiento	Desviación error entrenamiento
Despierto	58.48%	0	0.5888	0.4922
REM + sueño ligero	29.15%	0	0.3017	0.4591
Resto	76.33%	0	0.3290	0.4832

Tabla 8. Resultados Kernel lineal

Kernel polinomial grado 2				
Fases	Media error test	Desviación error test	Media error entrenamiento	Desviación error entrenamiento
Despierto	33.33%	0.001	0.3339	0.3717
REM + sueño ligero	83.10%	0.1275	0.9028	0.2463
Resto	72.32%	0.678	0.7633	0.4252

Tabla 9. Resultados Kernel polinomial

Kernel gaussiano				
------------------	--	--	--	--

Fases	Media error test	Desviación error test	Media error entrenamiento	Desviación error entrenamiento
Despierto	45.94%	0.0017	0.3339	0.4717
REM + sueño ligero	59.72%	0.4313	0.9028	0.2963
Resto	76.24%	0.0012	0.7659	0.4235

Tabla 10. Resultados Kernel gaussiano

4.2.3 k-NN

La precisión muestra una cota horizontal para un número de vecinos superior a 20. En la tabla 11 y en la figura 6 se muestran los resultados obtenidos.

K-NN Segunda Aproximación				
Número de vecinos	Precisión en test	Desviación típica de precisión en test	Precisión en entrenamiento	Desviación típica de precisión en entrenamiento
1	69.85%	0.0127	100%	0
2	75.48%	0.0075	84.87%	0.0028
3	74.46%	0.0101	83.88%	0.0027
4	75.41%	0.0085	82.12%	0.0029
5	75.47%	0.0084	81.40%	0.0028
10	77.25%	0.0081	79.56%	0.0024
20	78.18%	0.0062	79.04%	0.0021
30	78.36%	0.0069	78.79%	0.0017

Tabla 11. Resultados k-NN




Figura 6. Precisión k-NN

4.2.4 Discusión

Podemos ver que, en términos generales, los sistemas distinguen aceptablemente bien entre las clases 1 y 2, pero tienden a confundirse bastante a la hora de separar cualquiera de ellas de la tercera clase. La mejor precisión sigue obteniéndose con RNA y la peor con k-NN. La precisión de todos los sistemas ha bajado, en especial la de la SVM.

En esta aproximación, el trabajo que emplea k-NN, con el que buscamos comparar resultados, empleando los datos explicados en el apartado 4.2.3, obtuvo un resultado de un 94.49%, mientras que nuestro mejor resultado con esta técnica obtuvo un 75.54%, y el mejor sistema un 86.3%.

El algoritmo SVM nos ha dado unos resultados especialmente malos, aunque para una característica pueda ir bien, da unas desviaciones demasiado grandes.

En la Tabla 12 se recoge una comparación entre los mejores sistemas obtenidos con cada técnica y los estudiados previamente en la sección 3.

Autor	Media precisión RNA	Media precisión SVM	Media precisión k-NN
Este estudio	88.98%	54,73%	75.54%

Phan, H. [11]	-	-	98%
Huang, C.-S [4]	-	71%	-
Jo, H.G. [7]	-	87.5%	-
Fraiwan, L. [16]	84%	-	-

Tabla 12. Comparación de resultados

Aunque los resultados no alcanzan la precisión de los trabajos analizados en la sección 3 si que se superan las técnicas manuales de extracción de características de EEG y clasificación de las fases del sueño [18]. Ya que éstas son realizadas manualmente por un técnico, y es una tarea que consume mucho tiempo.

4.3 Aproximación 3

Hemos estimado que para esta aproximación la mejor forma de extraer características de una señal de EEG sería la transformada de ondícula, tal y como hicieron Lan, K.-C. [15] y Fraiwan, L. [16] en sus trabajos, en los cuales obtuvieron precisiones significativamente mayores. La transformada de ondícula es un tipo especial de transformada matemática que representa una señal en términos de versiones trasladadas y dilatadas, pudiendo representar de forma más eficiente cambios abruptos en la señal original. Todas las transformaciones de ondículas pueden ser consideradas formas de representación en tiempo-frecuencia y, por tanto, están relacionadas con el análisis armónico. Desafortunadamente no pudimos realizar el estudio de la transformada de la ondícula para la señal de un EEG porque no disponemos actualmente de las herramientas necesarias en esta materia. Por lo tanto hemos procedido con el análisis de la transformada de Fourier de tiempo reducido tal y como hicieron [4], [5] y [10] para la cual realizamos un pequeño estudio preliminar.

4.3.1 Estudios preliminares

En la Tabla 13, se indican los resultados obtenidos para la mejor red neuronal (100 entrenamientos). La figura 7 refleja la matriz de confusión.

Capas ocultas	Error en test	Desviación típica de error en test	Error en entrenamiento	Desviación típica de error en entrenamiento	Error en validación	Desviación típica error validación
1 capa con 8 neuronas	0.1478	0.0169	0.1450	0.0120	0.1941	0.0252

Tabla 13. Resultados RNA




Figura 7. Matriz de neuronas en la

confusión mejor RNA (8 capa oculta)

Utilizar la transformada de Fourier reduce la precisión obtenida con RNA. Esto se debe a que la transformada de Fourier representa datos como la suma de señales sinusoidales que no están localizadas ni en tiempo ni espacio. De esta manera, frecuencias elevadas tienden a ser asociadas con cambios abruptos (por ejemplo, la discontinuidad en los saltos de la señal cuadrada). En el dominio del tiempo reconocemos que la diferenciación enfatizará estos cambios abruptos, y las propiedades de la diferenciación declaran que, consistentemente con este resultado, las altas frecuencias son amplificadas en relación con las bajas frecuencias.

Teniendo esto en cuenta hemos llegado a la conclusión que el mejor método para extraer características de la transformada de Fourier de la señal del EEG, es extraer la media y la desviación típica para cada marco de las franjas entre 0 y 5 Hz, y entre 5 y 10 Hz.

4.3.2 RNA

En la Tabla 14, se indican los resultados obtenidos para los patrones de test. Las figura 8 refleja

la matriz de confusión de la mejor red neuronal.

Capas ocultas	Error en test	Desviación típica de error en test	Error en entrenamiento	Desviación típica de error en entrenamiento	Error en validación	Desviación típica error validación
8	0.0671	0.0125	0.0659	0.0062	0.109	0.0035
10	0.0656	0.0123	0.0658	0.0058	0.1024	0.00314
2 y 2	0.1150	0.0942	0.1141	0.0925	0.1461	0.0852
4 y 3	0.0826	0.0547	0.0821	0.0527	0.1163	0.0528
6 y 2	0.0923	0.0706	0.0919	0.0672	0.1284	0.0660

Tabla 14. Resultados RNA




Figura 8. Matriz de confusión mejor RNA (10 neuronas en la capa oculta)

4.3.3 SVM

Se muestran los resultados obtenidos con kernel gaussiano (escala por defecto) en la tabla 15.

Los resultados mostrados son con una iteración.

Kernel gaussiano				
Fases	Media error test	Desviación error test	Media error entrenamiento	Desviación error entrenamiento
Despierto	0.6802	0.4665	0.6661	0.4635
REM + sueño ligero	0.0212	0.1442	0.0066	0.0811
Resto	0.3127	0.4640	0.3132	0.4639

Tabla 15. Resultados Kernel gaussiano

4.3.4 k-NN

La precisión muestra una cota horizontal para un número de vecinos superior a 20. En la tabla 16 y en la figura 9 se muestran los resultados obtenidos.

K-NN Tercera Aproximación				
Número de vecinos	Precisión en test	Desviación típica de precisión en test	Precisión en entrenamiento	Desviación típica de precisión en entrenamiento
1	78.21%	0.0118	100%	0
2	78.92%	0.0108	86.36%	0.0031
3	77.62%	0.0101	86.06%	0.0032
4	78.80%	0.0079	86.39%	0.0034
5	78.56%	0.0099	83.18%	0.0035
10	79.15%	0.0085	81.13%	0.0027
20	78.45%	0.0075	80.17%	0.0033
30	78.33%	0.0070	79.29%	0.0027
50	78.56%	0.0063	79.02%	0.0026

Tabla 16. Resultados k-NN

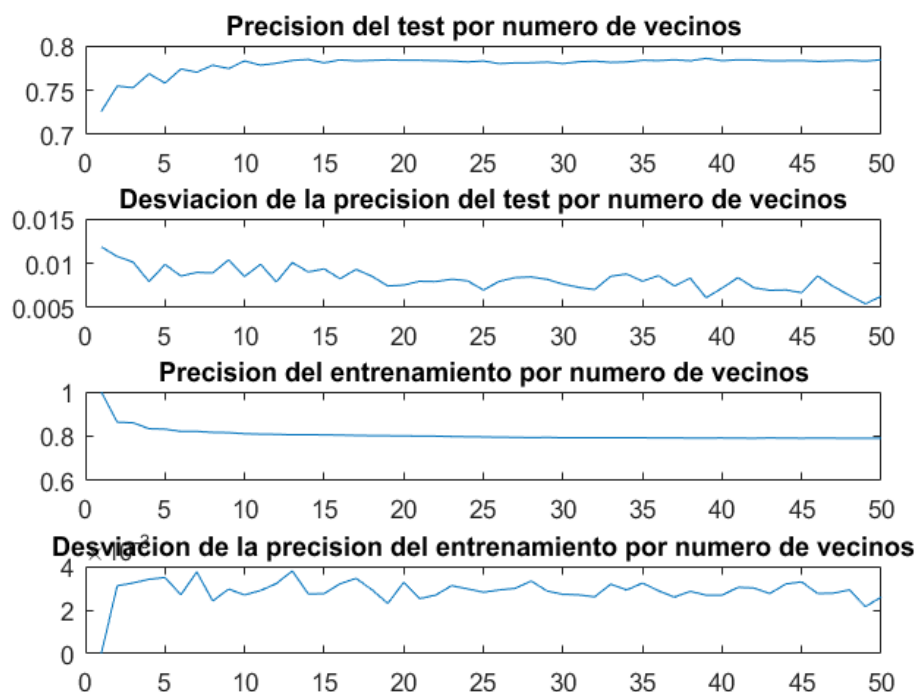


Figura 9. Precisión k-NN

4.3.5 Discusión

Podemos ver que, en términos generales, los sistemas distinguen aceptablemente bien entre las clases 1 y 2, pero tienden a confundirse bastante a la hora de separar cualquiera de ellas de la tercera clase. La mejor precisión sigue obteniéndose con RNA y la peor con SVM. La precisión de todos los sistemas ha bajado, en especial la de la SVM.

En esta aproximación, el trabajo que emplea SVM, con el que buscamos comparar resultados, empleando los datos explicados en el apartado 4.3.3, obtuvo un resultado de un 71%, mientras que nuestro mejor resultado con esta técnica obtuvo un 66.2%.

El algoritmo SVM nos ha dado unos resultados especialmente malos, aunque para una característica pueda ir bien, da unas desviaciones demasiado grandes.

En la Tabla 19 se recoge una comparación entre los mejores sistemas obtenidos con cada técnica y los estudiados previamente en la sección 3.

Autor	Media precisión	Media precisión	Media precisión
-------	-----------------	-----------------	-----------------

	RNA	SVM (Gaussiano)	k-NN
Este estudio	91.54%	66.2%	78.51%
Phan, H. [11]	-	-	98%
Huang, C.-S [4]	-	71%	-
Jo, H.G. [7]	-	87.5%	-
Fraiwani, L. [16]	84%	-	-

Tabla 17. Comparación de resultados

Aunque los resultados no alcanzan la precisión de los trabajos analizados en la sección 3 si que se superan las técnicas manuales de extracción de características de EEG y clasificación de las fases del sueño [18]. Ya que éstas son realizadas manualmente por un técnico, y es una tarea que consume mucho tiempo.

4.4 - Aproximación 4

En la aproximación anterior no disponíamos de las herramientas para desarrollar un estudio consistente de la transformada de ondícula aplicada a nuestro problema, pero en este apartado pudimos compararla con la transformada de Fourier de tiempo reducido. Los resultados se pueden observar en el estudio preliminar que mostramos a continuación.

4.4.1 Estudio preliminar

En la Tabla 18, se indican los resultados obtenidos para las mejores redes neuronales (100 entrenamientos). El estudio se realizó con la transformada continua y un escalograma “sym2” con escala 1. En la figura 10 se muestra una gráfica con dicha función y escalograma.

Capas ocultas	Error en test	Desviación típica de error en test	Error en entrenamiento	Desviación típica de error en entrenamiento	Error en validación	Desviación típica error validación

				to		
1 capa con 8 neuronas (Fourier - aproximación 3)	0.1478	0.0169	0.1450	0.0120	0.1941	0.0252
1 capa con 8 neuronas (ondícula)	0.1030	0.0161	0.1005	0.0105	0.2255	0.0470

Tabla 18. Resultados RNA




Figura 10. Transformada de ondícula continua

Teniendo esto en cuenta hemos llegado a la conclusión que el mejor método para extraer características de la señal del EEG, es extraer la media y la desviación típica para la transformada de ondícula.

En esta aproximación utilizaremos las mismas características extraídas en la aproximación anterior. Hemos decidido eliminar la fase despierto ya que presenta un número de patrones

desbalanceado comparado con el resto de fases, por esto nos centraremos en clasificar entre fase 1, fase 2, fase 3 + fase 4 (como se menciona en estudios modernos y en [12], estas 2 fases son consideradas la misma) y fase REM. Además, debido a la naturaleza del dominio de nuestro problema hemos decidido utilizar los datos de 4 pacientes para poder obtener así un estudio más uniforme y generalizado.

4.4.2 RNA

En la Tabla 13, se indican los resultados obtenidos para los patrones de test. Las figuras 7 y 8 reflejan la matriz de confusión y la estructura de la mejor red neuronal.

Capas ocultas	Error en test	Desviación típica de error en test	Error en entrenamiento	Desviación típica de error en entrenamiento	Error en validación	Desviación típica error validación
1	0.3066	0.0455	0.3054	0.0360	0.4683	0.0298
3	0.2657	0.0240	0.2673	0.0178	0.4843	0.0381
5	0.2540	0.0243	0.2549	0.0147	0.4811	0.0312
7	0.2503	0.0230	0.2455	0.0100	0.4947	0.0483
8	0.2552	0.0238	0.2453	0.0096	0.4842	0.0390
10	0.2445	0.0155	0.2391	0.0121	0.4962	0.0309
2 y 2	0.3124	0.0692	0.3037	0.0603	0.4745	0.0352
4 y 3	0.2601	0.0466	0.2593	0.0375	0.4841	0.0460

6 y 2	0.2637	0.0362	0.2610	0.0352	0.4895	0.0357
-------	--------	--------	--------	--------	--------	--------

Tabla 20. Resultados RNA




Figura 12. Matriz de confusión mejor RNA (10 neuronas en la capa oculta)




Figura 13. Estructura de la mejor RNA (10 neuronas en la capa oculta)

4.4.3 SVM

Se muestran los resultados obtenidos con un kernel lineal en las tabla 21.

Kernel polinomial grado 2				
Fases	Media precisión test	Desviación precisión test	Media precisión entrenamiento	Desviación precisión entrenamiento
Sueño ligero	92.06%	0.2705	92.03%	0.2708
Sueño	56.69%	0.4959	56.68%	0.4956
Sueño profundo	85.38%	0.3536	85.25%	0.3547
REM	79.25%	0.4058	79.40%	0.4045

Tabla 21. Resultados Kernel polinomial

4.4.4 k-NN

La precisión muestra una cota horizontal para un número de vecinos superior a 20. En la tabla 22 y en la figura 14 se muestran los resultados obtenidos.

K-NN Segunda Aproximación				
Número de vecinos	Precisión en test	Desviación típica de precisión en test	Precisión en entrenamiento	Desviación típica de precisión en entrenamiento
2	82.25%	0.0104	90.16%	0.0012
3	81.91%	0.0065	88.96%	0.0017
4	82.75%	0.0044	88.06%	0.0015
5	83.26%	0.0042	87.38%	0.0015
10	84.38%	0.0030	86.09%	0.0012
20	85.18%	0.0024	85.75%	0.0008
30	85.32%	0.0017	85.59%	0.0005
50	85.47%	0.0010	85.55%	0.0003

Tabla 22. Resultados k-NN

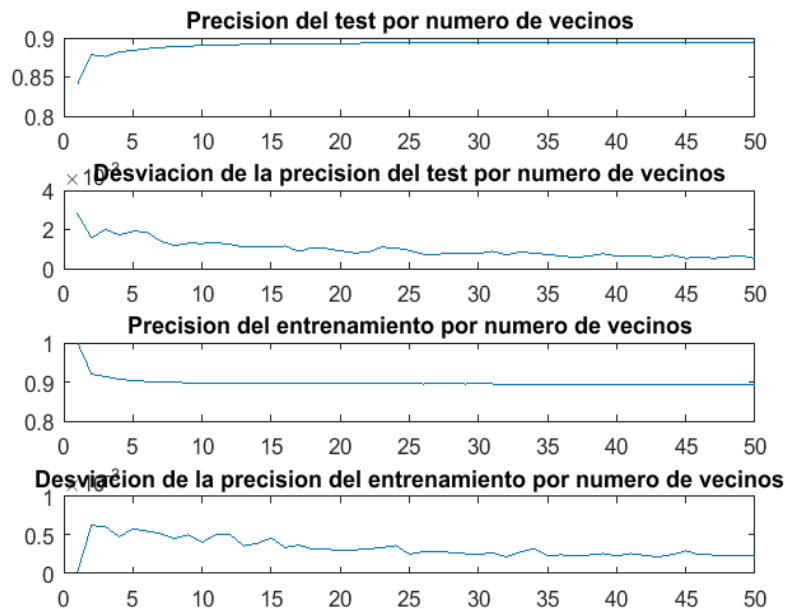


Figura 14. Precisión k-NN

4.4.5 Discusión

Podemos ver que, en términos generales, los sistemas distinguen aceptablemente bien entre las clases 1, 3 y 4, pero tienden a confundirse bastante a la hora de separar la clase 2 de las clases 1 y 4. La mejor precisión se obtiene con el algoritmo k-NN y la peor con RNA. La precisión de todos los sistemas ha bajado, excepto el algoritmo k-NN, que mejora ligeramente.

En esta aproximación, el trabajo que emplea Phan, H. [11], con el que buscamos comparar resultados, empleando los datos explicados en el apartado 4. Phan, H. [11], obtuvo un resultado de un 98%, mientras que nuestro mejor resultado con esta técnica obtuvo un 83,81%, y el mejor sistema un 85.47%.

El algoritmo SVM nos ha dado unos resultados especialmente malos, aunque para una característica pueda ir bien, da unas desviaciones demasiado grandes.

En la Tabla 23 se recoge una comparación entre los mejores sistemas obtenidos con cada técnica y los estudiados previamente en la sección 3.

Autor	Media precisión RNA	Media precisión SVM	Media precisión k-NN
Este estudio	80.0%	88.14%	89.41%
Phan, H. [11]	-	-	98%
Huang, C.-S [4]	-	71%	-
Jo, H.G. [7]	-	87.5%	-
Fraiwan, L. [16]	84%	-	-

Tabla 23. Comparación de resultados

5 - CONCLUSIONES

Después de desarrollar cuatro aproximaciones no hemos podido obtener unos resultados mejores que los publicados en artículos modernos. En general y observando los resultados obtenidos, resumidos en la Tabla 26, se puede percibir que un sistema de este tipo puede llegar a ser capaz de clasificar con buena precisión distintas fases del sueño, en menor o mayor medida, dependiendo de la características que se extraigan.

Por lo que hemos podido comprobar, los sistemas de redes de neuronas artificiales suponen una mejor clasificación en todos los casos para el problema que hemos estudiado que los sistemas SVM o k-NN. En el caso de SVM, al menos con el enfoque que le hemos dado en nuestro trabajo, no es válido para resolver el problema. k-NN quizás podría funcionar mejor con otras características, ya que en las primeras aproximaciones aunque no alcanzaba el nivel de la RNA, arrojaba resultados aceptables.

A lo largo de este trabajo, nos hemos encontrado con algunas dificultades relacionadas que hemos tenido que resolver. El primero de ellos fue encontrarnos con que algunos datos del paciente no estaban clasificados correctamente en el hipnograma, o bien se los había marcado como irregularidades. Además no todos los sujetos de nuestra base de datos tenían suficientes datos de todas las fases del sueño. Por otro lado, tuvimos que lidiar con que algunos patrones de temperatura corporal también presentaban valores anómalos.

Los otros problemas reseñables en la elaboración de este trabajo tuvieron que ver con las SVM,

como por ejemplo el desarrollo de las SVM multiclase utilizando el algoritmo uno contra todos y la realización de las pruebas que, debido a la utilización del algoritmo anteriormente mencionado, se demoraban notablemente.

Autor	Media precisión RNA	Media precisión SVM	Media precisión k-NN
Aproximación 1 (dormido o despierto)	88.98%	54,73%	75.54%
Aproximación 2 (despierto, fase 1 + REM o demás fases)	91.51%	78.35%	64.91%
Aproximación 3 (dominio de la frecuencia)	91.54%	66.2%	78.51%
Aproximación 4 (todos los pacientes)	80.0%	88.14%	89.41%
Phan, H. [11]	-	-	98%
Huang, C.-S [4]	-	71%	-
Jo, H.G. [7]	-	87.5%	-
Fraiwan, L. [16]	84%	-	-

Tabla 26. Comparación de resultados

6 - TRABAJO FUTURO

Una buena continuación sería intentar extraer nuevas características, o modificar las ya existentes, que nos permitieran mejorar la clasificación obtenida en la última aproximación. Especialmente sería una buena decisión incorporar las ondículas como método de extracción de características.

Una vez conseguido esto, las fases del sueño estarían completamente separadas, por lo que no habría que ampliar en ese aspecto. Un posible problema a resolver a mayores podría ser la detección de trastornos del sueño según la fase.

7 - BIBLIOGRAFÍA

1. Dement, W. & Kleitman, N. (1957). *The relation of eye movements during sleep to dream activity: An objective method for the study of dreaming.*
2. Goldberger AL, Amaral LAN, Glass L, Hausdorff JM, Ivanov PCh, Mark RG, Mietus JE, Moody GB, Peng C-K, Stanley HE. PhysioBank, PhysioToolkit, and PhysioNet: Components of a New Research Resource for Complex Physiologic Signals. *Circulation* 101(23):e215-e220 [Circulation Electronic Pages; <http://circ.ahajournals.org/content/101/23/e215.full>]; 2000 (June 13).

<https://www.physionet.org/physiobank/database/sleep-edf/>

3. Bastiaan Kemp, Aeilko H. Zwinderman, Bert Tuk, Hilbert A. C. Kamphuisen, and Josefin J. L. Oberyé (2000). “Analysis of a Sleep-Dependent Neuronal Feedback Loop: The Slow-Wave Microcontinuity of the EEG”. *IEE Transactions on biomedical engineering*, Vol. 47, No. 9 <https://www.physionet.org/physiobank/database/sleep-edfx/Papers/2000-Kemp---neurofeedback.pdf>
4. Huang, C.-S.; Lin, C.-L.; Ko, L.-W.; Liu, S.-Y.; Sua, T.-P.; Lin, C.-T. *A hierarchical classification system for sleep stage scoring via forehead EEG signals*. In Proceedings of the IEEE Symposium on Computational Intelligence, Cognitive Algorithms, Mind, and Brain (CCMB), Singapore, 16–19 April 2013; pp. 1–5. *Sleep Stage Classification Using EEG*.
https://www.researchgate.net/publication/306391958_Sleep_Stage_Classification_Using_EEG_Signal_Analysis_A_Comprehensive_Survey_and_New_Investigation
5. Radha, M.; Garcia-Molina, G.; Poel, M.; Tononi, G. *Comparison of feature and classifier algorithms for online automatic sleep staging based on a single EEG signal*. In Proceedings of the 36th IEEE Annual International Conference of Engineering in Medicine and Biology Society, Chicago, IL, USA, 26–30 August 2014; pp. 1876–1880.
6. Yu, S.; Li, P.; Lin, H.; Rohani, E.; Choi, G.; Shao, B.; Wang, Q. *Support vector machine based detection of drowsiness using minimum EEG features*. In Proceedings of the IEEE International Conference on Social Computing (SocialCom), Alexandria, VA, USA, 8–14 September 2013; pp. 827–835.
7. Jo, H.G.; Park, J.Y.; Lee, C.K.; An, S.K.; Yoo, S.K. *Genetic fuzzy classifier for sleep stage identification*. *Comput. Biol. Med.* 2010,40, 629–634.
8. Gudmundsson, S.; Runarsson, T.P.; Sigurdsson, S. Automatic sleep staging using support vector machines with posterior probability estimates. In Proceedings of the International Conference on Computational Intelligence for Modelling, Control and Automation and International Conference on Intelligent Agents, Web Technologies and Internet Commerce (CIMCA-IAWTIC), Vienna, Austria, 28–30 November 2005; pp. 366–372.
9. Le, Q.K.; Truong, Q.D.K.; Vo, V.T. A tool for analysis and classification of sleep stages. In Proceedings of the IEEE International Conference on Advanced Technologies for Communications (ATC), Da Nang, Vietnam, 2–4 August 2011; pp. 307–310. *Sleep Stage Classification Using EEG*.
10. Lajnef, T.; Chaibi, S.; Ruby, P.; Aguera, P.-E.; Eichenlaub, J.-B.; Samet, M.; Kachouri, A.; Jerbi, K. *Learning machines and sleeping brains: Automatic sleep stage classification using decision-tree multi-class support vector machines*. *J. Neurosci. Methods* 2015,250, 94–105.
11. Phan, H.; Do, Q.; Do, T.-L.; Vu, D.-L. *Metric learning for automatic sleep stage classification*. In Proceedings of the 35th IEEE Annual International Conference of the Engineering in Medicine and Biology Society (EMBC), Osaka, Japan, 3–7 July 2013; pp.

5025–5028.

12. Hassan, A.R.; Bhuiyan, M.I.H. *Automatic sleep scoring using statistical features in the EMD domain and ensemble methods*. Biocybern. Biomed. Eng. 2016,36, 248–255.
13. Hassan, A.R.; Bashar, S.K.; Bhuiyan, M.I.H. *On the classification of sleep states by means of statistical and spectral features from single channel electroencephalogram*. In Proceedings of the IEEE International Conference on Advances in Computing, Communications and Informatics (ICACCI), Kochi, India, 10–13 August 2015; pp. 2238–2243.
14. Rodríguez-Sotelo, J.L.; Osorio-Forero, A.; Jiménez-Rodríguez, A.; Cuesta-Frau, D.; Cirugeda-Roldán, E.; Peluffo, D. *Automatic sleep stages classification using EEG entropy features and unsupervised pattern analysis techniques*. Entropy 2014,16, 6573–6589.
15. Lan, K.-C.; Chang, D.-W.; Kuo, C.-E.; Wei, M.-Z.; Li, Y.-H.; Shaw, F.-Z.; Liang, S.-F. *Using off-the-shelf lossy compression for wireless home sleep staging*. J. Neurosci. Methods 2015,246, 142–152.
16. Fraiwan, L.; Lweesy, K.; Khasawneh, N.; Wenz, H.; Dickhaus, H. *Automated sleep stage identification system based on time–frequency analysis of a single EEG channel and random forest classifier*. Comput. Methods Progr. Biomed. 2012,108, 10–19.
17. Fraiwan, L.; Lweesy, K.; Khasawneh, N.; Fraiwan, M.; Wenz, H.; Dickhaus, H. *Time frequency analysis for automated sleep stage identification in fullterm and preterm neonates*. J. Med. Syst. 2011 ,35, 693–702
18. Simon Kern. *Automatic Sleep Stage Classification*. Research Gate. <https://www.researchgate.net/project/Automatic-Sleep-Stage-Classification>